Indicaciones para el Ajuste de la Base de Datos GEM APS

Taller 3 - Analítica de Datos para la Toma de Decisiones

2026-02-19

Contents

Introducción **1**

PARTE 0: CARGA DE LA INFORMACIÓN **2**

PARTE 1: ELIMINACIÓN DE COLUMNAS **2**
1.1 Eliminar columnas con muchos valores faltantes (NA >= 1203) . . . 2
1.2 Eliminar columnas específicas (lista predefinida) . . . 2

PARTE 2: CREACIÓN DE NUEVAS VARIABLES **3**
2.1 Variable `age7c` (Edad en categorías) . . . 3

PARTE 3: RECODIFICACIÓN CON ETIQUETAS (Value Lookup) **4**
3.1 Variable `knowentR` . . . 4
3.2 Variables escala Likert . . . 4
3.3 Variables Likert adicionales . . . 5
3.4 Variables Sí/No (bstart, bjobst, ownmge, omjobst, futsup, discent, busang, doublecount) . . . 5
3.5 Variable `gender` . . . 5
3.6 Variable `hhsize` . . . 5
3.7 Variable `occup` . . . 5
3.8 Variable `COhhinc` . . . 6
3.9 Variable `COREduc` . . . 6
3.10 Variable `COpost` . . . 6
3.11 Variable `contact` . . . 6
3.12 Variable `cphhinc` . . . 7
3.13 Variable `COXXNIVSE` . . . 7
3.14 Variable `COxxetn` . . . 7
3.15 Variable `CONACIO` . . . 7
3.16 Variables SU_CSTLOC, SU_CSTNAT, SU_CSTEXP . . . 8
3.17 Variables SU_NEWPROD, SU_NEWPROC . . . 8

PARTE 4: ESTRUCTURA DEL WORKFLOW EN KNIME **8**

ANEXO: Tablas diccionario **9**

Introducción

Este documento describe los ajustes que los estudiantes deben realizar sobre la base de datos GEM APS. Para cada variable o grupo de variables se indica: (1) el ajuste a realizar, (2) los valores y etiquetas, y (3) la solución equivalente en **KNIME** con el nodo correspondiente.

Dataset: GEM Adult Population Survey (APS) - Individual Level Data

PARTE 0: CARGA DE LA INFORMACIÓN

Paso inicial obligatorio: Antes de realizar cualquier ajuste, se debe cargar la base de datos en KNIME.

Nodo	Configuración
Excel Reader	*Ruta:* `IO` → `Read` → `Excel Reader` 1. Seleccionar el archivo de la base GEM (formato .xlsx o .xls) 2. Especificar la hoja a leer (generalmente la primera) 3. Verificar que la primera fila contenga los nombres de las columnas 4. El nodo entregará la tabla de datos en el puerto de salida para conectarla al resto del workflow

Alternativa para archivos .sav (SPSS): Usar el nodo **SPSS Reader** (*Ruta:* `IO` → `Read` → `SPSS Reader`) si la base está en formato SPSS.

PARTE 1: ELIMINACIÓN DE COLUMNAS

1.1 Eliminar columnas con muchos valores faltantes (NA >= 1203)

Objetivo: Eliminar variables que tienen 1203 o más valores NA (no aplicables o sin respuesta).

Indicaciones:

- Calcular el conteo de NA por cada columna.
- Identificar las columnas donde `Conteo_NA >= 1203`.
- Eliminar esas columnas del dataset.

Solución en KNIME:

Nodo	Configuración
Missing Value Column Filter	*Ruta:* `Data Manipulation` → `Filter` → `Missing Value Column Filter` 1. Seleccionar **todas las columnas** para evaluar 2. Criterio: **"By number of missing values"** 3. Umbral: **1203** (o el valor que corresponda al umbral deseado) 4. Opción: **"Remove columns with at least X missing values"**

Alternativa: Si necesita un umbral dinámico (porcentaje), use **"By percentage of missing values"** y calcule el porcentaje equivalente (ej: 1203/número_total_filas * 100).

1.2 Eliminar columnas específicas (lista predefinida)

Objetivo: Eliminar un conjunto de columnas que no se utilizarán en el análisis (variables técnicas, duplicadas, o de años específicos).

Columnas a eliminar: `ctryalp`, `setid`, `ID`, `REGION`, `WBINC`, `WBincREV`, `yrsurv`, `weight`, `WEIGHT_L`, `WEIGHT_A`, `GEMOCCU`, `GEMWORK`, `GEMWORK3`, `GEMHHINC`, `GEMEDUC`, `UNEDUC`, `UNEDUC97`, `COZONAROU`, `Bstart22`, `BJOBST22`, `OWNMGE22`, `OMJOBST22`, `BUSANG22`, `FUTSUP22`, `DISCEN22`, `KNOWEN22`, `OPPORT22`, `SUSKIL22`, `FRFAIL22`, `EASYST22`, `OPPISM22`, `PROACT22`, `CREATIV22`, `VISION22`, `EQUALI22`, `NBGOOD22`, `NBSTAT22`,

NBMEDI22, INDSUP22, CULSUP22, SUB, SUBA, SUBO, SUBOA, SUBOANW, OMBABYX, OMESTBX, BABYBUSM, BABYBUSO, ESTBBUSM, ESTBBUSO, SUBOANWC, SUBOANW1, BABYBUS1, ESTBBUS1, TEA22, ANYBUSOW, TEA22MAL, TEA22FEM, BUSANGVL, SU_HITEC, BB_HITEC, EB_HITEC, TEAHITEC, EXTHITEC, su_22TEC, bb_22TEC, SU_SIC4C, BB_SIC4C, EB_SIC4C, SU_ISIC4_1D, BB_ISIC4_1D, EB_ISIC4_1D, TEAISIC4_1D, TEASIC4C, TEA22S1C, TEA22S2C, TEA22S3C, TEA22S4C, BO_EXAGR, EXIT_CTD, EXIT_ENT, TEA22EMP, su_22emp, bb_22emp, EB_22EMP, TEA22HJG, su_22hjg, bb_22hjg, EB_22HJG, tea22kix, su_22kix, bb_22kix, eb_22kix, tea22hix, su_22hix, bb_22hix, eb_22hix, FUTSUPNO, SU_MKSC, BB_MKSC, EB_MKSC, BB_CSTLOC, BB_CSTNAT, BB_CSTEXP, BB_NEWPROD, BB_NEWPROC, EB_CSTLOC, EB_CSTNAT, EB_CSTEXP, EB_NEWPROD, TEAIMPACT1, TEAIMPACT2, OPPIS_1, OPPIS_2, OPPIS_3, PROAC_1, PROAC_2, PROAC_3, CREATI_1, CREATI_2, CREATI_3, VISIO_1, VISIO_2, VISIO_3, SOCEN_1, SOCEN_2, SOCEN_3, INDSP22A, INDSP22B, INDSP22C, INDSP22D, CULSP22A, CULSP22B, CULSP22C, CULSP22D, TEA22IND, TEA22SPON, SU_SPON, SU_IND, BB_SPON, BB_IND, EB_SPON, EB_IND, TEAactivityr, MSURV

Solución en KNIME:

Nodo	Configuración
Column Filter	*Ruta:* `Data Manipulation` → `Filter` → `Column Filter` 1. Modo: **"Exclude"** (excluir columnas) 2. Seleccionar o pegar la lista de columnas a excluir 3. Alternativa: Crear un archivo CSV/Excel con los nombres y usar **Table Reader** + **Column Filter** con referencia a esa tabla

---

PARTE 2: CREACIÓN DE NUEVAS VARIABLES

2.1 Variable `age7c` (Edad en categorías)

Objetivo: Crear una variable categórica a partir de `age` con 7 rangos de edad más categorías de no respuesta.

Reglas de recodificación:

Rango de `age`	Valor	Etiqueta
age < 18	1	Menos de 18
18 <= age <= 24	2	18-24
25 <= age <= 34	3	25-34
35 <= age <= 44	4	35-44
45 <= age <= 54	5	45-54
55 <= age <= 64	6	55-64
65 <= age <= 99	7	65-99
NA (age)	-2	Sin respuesta/Rechaza

Solución en KNIME:

Nodo	Configuración

Rule Engine	*Ruta:* `Data Manipulation` → `Transform` → `Rule Engine`
	1. Columna de salida: `age7c`
	2. Reglas: `$age$ < 18 => "Menos de 18"`
	`$age$ >= 18 AND $age$ <= 24 => "18-24"`
	`$age$ >= 25 AND $age$ <= 34 => "25-34"`
	`$age$ >= 35 AND $age$ <= 44 => "35-44"`
	`$age$ >= 45 AND $age$ <= 54 => "45-54"`

Nodo	Configuración

	`$age$ >= 55 AND $age$ <= 64 => "55-64"`
	`$age$ >= 65 AND $age$ <= 99 => "65-99"`
	`$age$ IS MISSING => "Sin respuesta/Rechaza"`
	3. Default: `"Sin respuesta/Rechaza"`

PARTE 3: RECODIFICACIÓN CON ETIQUETAS (Value Lookup)

Para las siguientes variables se reemplazan valores numéricos por etiquetas descriptivas. En KNIME se usa el nodo **Value Lookup** con una tabla diccionario.

Procedimiento general en KNIME:

1. Crear un archivo Excel o CSV con dos columnas: **Valor_Original** y **Etiqueta**.
2. Nodo **Excel Reader** o **CSV Reader** para cargar el diccionario.
3. Nodo **Value Lookup**: conectar la tabla de datos (puerto 1) y el diccionario (puerto 2).
4. Configurar: columna a buscar = variable de interés; columna clave del diccionario = Valor_Original; columna de reemplazo = Etiqueta.
5. Opción **"Replace"** para sustituir la columna original.

3.1 Variable `knowentR`

Valor	Etiqueta
0	Ninguno
1	Uno
2	De 2 a 4
3	5 o más
-1	No lo sabe
-2	Rechaza

Nodo KNIME: Value Lookup (con diccionario)

3.2 Variables escala Likert

Variables: `opportL`, `suskillL`, `fearfailL`, `easystartL`

Valor	Etiqueta
5	Completamente de acuerdo
4	Algo de acuerdo
3	Ni de acuerdo ni en desacuerdo
2	Poco de acuerdo
1	Nada de acuerdo
-1	No lo sabe
-2	Rechaza

Nodo KNIME: Value Lookup. Crear un diccionario y aplicarlo a cada variable.

3.3 Variables Likert adicionales

Variables: `oppism`, `proact`, `creativ`, `vision`, `equalincL`, `nbgoodcL`, `nbstatusL`, `nbmediaL`, `nbsocentL`

Mismo mapeo que 3.2. Nodo KNIME: Value Lookup con el mismo diccionario Likert.

3.4 Variables Sí/No (bstart, bjobst, ownmge, omjobst, futsup, discent, busang, doublecount)

Valor	Etiqueta
1	Sí
2	No
-1	No sabe
-2	Rechaza
0	Otro

Nodo KNIME: Value Lookup

3.5 Variable `gender`

Valor	Etiqueta
1	Hombre
2	Mujer
-1	No sabe
-2	Rechaza

3.6 Variable `hhsize`

Valor	Reemplazo
-1	No sabe
-2	Rechaza
Otros	Mantener valor original

Nodo KNIME: Rule Engine o String Replacer

3.7 Variable `occup`

Valor	Etiqueta
1	Empleado por cuenta ajena a tiempo completo
2	Empleado por cuenta ajena a tiempo parcial
3	Autoempleado
4	Desempleado
5	Jubilado
6	Estudiante
7	Labores del hogar
8	No está buscando empleo
9	Otro caso (Especificar)
10	Cuidador de un miembro de su familia

Valor	Etiqueta
-1	No sabe
-2	No contesta

3.8 Variable `COhhinc`

Valor	Etiqueta
1	Menos de 1 SMMLV
2	Entre 1 y 2 SMMLV
3	Más de 2 SMMLV y menos de 3 SMMLV
4	Más de 3 SMMLV y menos de 4 SMMLV
5	Más de 4 SMMLV y menos de 5 SMMLV
6	Más de 5 SMMLV y menos de 6 SMMLV
7	Más de 6 SMMLV
-1	No sabe
-2	Rechaza

3.9 Variable `COREduc`

Valor	Etiqueta
0	Sin estudios
1	Primaria incompleta
2	Primaria completa
3	Secundaria incompleta
4	Secundaria completa
5	Técnico incompleto
6	Técnico completo
7	Tecnológico incompleto
8	Tecnológico completo
9	Universitario incompleto
10	Universitario completo
11	Posgrado (especialización, maestría, doctorado)
-1	No sabe
-2	Rechaza

3.10 Variable `COpost`

Valor	Etiqueta
-3	No es aplicable
-1	No sabe
-2	Rechaza

3.11 Variable `contact`

Valor	Etiqueta
1	Presencial (cara a cara)
2	Línea telefónica fija

Valor	Etiqueta
3	Línea telefónica móvil
4	Otro caso

3.12 Variable `cphhinc`

Valor	Etiqueta
1	Han disminuido considerablemente
2	Han disminuido un poco
3	No han mostrado cambios sustanciales
4	Han aumentado un poco
5	Han aumentado considerablemente
-1	No sabe
-2	Rechaza

3.13 Variable `COXXNIVSE`

Valor	Etiqueta
1	Estrato 1
2	Estrato 2
3	Estrato 3
4	Estrato 4
5	Estrato 5
6	Estrato 6
-1	No sabe
-2	Rechaza

3.14 Variable `COxxetn`

Valor	Etiqueta
1	Afrodescendiente
2	Asiático
3	Blanco
4	Indígena
5	Mulato
6	Mestizo
7	Raizal
8	Otro (Especificar)
-1	No sabe
-2	Rechaza

3.15 Variable `CONACIO`

Valor	Etiqueta
1	Colombiana
2	Otra

3.16 Variables SU__CSTLOC, SU__CSTNAT, SU__CSTEXP

Valor	Etiqueta
1	Sí
2	No
-1	No lo sabe
-2	Rechaza

3.17 Variables SU__NEWPROD, SU__NEWPROC

Valor	Etiqueta
1	No, no ofrezco ningún producto o servicio que sea nuevo
2	Nuevo para la gente de la zona en la que vive
3	Nuevo para la gente de su país
4	Nuevo en el mundo
-1	No lo sabe
-2	Rechaza

PARTE 4: ESTRUCTURA DEL WORKFLOW EN KNIME

```
[Excel/SPSS Reader]
       |
       v
[Missing Value Column Filter]  --> Eliminar columnas con NA mayor o igual a 1203
       |
       v
[Column Filter]  --> Excluir lista de columnas predefinidas
       |
       v
[Rule Engine]  --> Crear age7c
       |
       v
[Value Lookup] x N  --> Aplicar diccionarios a cada variable
       |
       v
[Column Filter]  --> Excluir columnas de la lista delete_colum
       |
       v
[Excel Writer]  --> Guardar Base_Final_Proyecto.xlsx
```

Archivo de salida final: La base de datos depurada debe exportarse con el nombre `Base_Final_Proyecto.xlsx`.

Configuración del nodo Excel Writer:

Nodo	Configuración
Excel Writer	*Ruta:* `IO` → `Write` → `Excel Writer` 1. Especificar la ruta y nombre del archivo: **Base__Final__Proyecto.xlsx** 2. Seleccionar la hoja de salida (por defecto “Sheet1”)

Nodo	Configuración
	3. Conectar el puerto de entrada al último nodo del workflow (Column Filter)

Recomendación: Crear **tablas diccionario** en Excel (una hoja por tipo de mapeo: Likert, Sí/No, occup, COhhinc, etc.) y conectarlas a múltiples nodos Value Lookup.

ANEXO: Tablas diccionario

Diccionario Likert:

Valor	Etiqueta
5	Completamente de acuerdo
4	Algo de acuerdo
3	Ni de acuerdo ni en desacuerdo
2	Poco de acuerdo
1	Nada de acuerdo
-1	No lo sabe
-2	Rechaza

Diccionario Sí/No:

Valor	Etiqueta
1	Sí
2	No
-1	No sabe
-2	Rechaza
0	Otro

Documento generado para el Taller 3 - Ajuste Base de Datos GEM APS