Taller Aplicado: Análisis y Predicción de Churn Bancario

Machine Learning para Economía y Finanzas

Caso de Estudio: Predicción de Churn en una Entidad Financiera

Una entidad financiera ha detectado un incremento en la tasa de abandono de clientes durante los últimos periodos. El área de analítica ha desarrollado un modelo de regresión logística que permite estimar la probabilidad de que un cliente abandone el banco (churn), utilizando información demográfica, financiera y comportamental.

La variable objetivo del estudio es:

- Exited = 1: El cliente abandonó el banco
- Exited = 0: El cliente permanece activo

El propósito de este taller es analizar la estructura de los datos, estudiar sus distribuciones, identificar relaciones bivariadas con la variable respuesta y comprender la interpretación del modelo mediante Odds Ratios.

Contexto de las Variables del Modelo

Las siguientes variables forman parte del modelo predictivo:

Variable	Descripción	Tipo
CreditScore	Puntaje crediticio del cliente. Indica el nivel de riesgo financiero histórico del cliente.	Numérica
Geography	País de residencia del cliente (France, Germany, Spain). Se codifica mediante variables dummy tomando France como categoría base.	Categórica
Gender	Género del cliente (Female, Male). Se codifica como variable dummy.	Categórica
Age	Edad del cliente en años. Variable demográfica relevante en decisiones financieras.	Numérica
Tenure	Número de años que el cliente ha permanecido en el banco.	Numérica
Balance	Saldo disponible en la cuenta bancaria del cliente.	Numérica
NumOfProducts	Número de productos financieros que el cliente posee en el banco.	Numérica
HasCrCard	Indica si el cliente posee tarjeta de crédito (0 = No, 1 = Sí).	Binaria
IsActiveMember	Indica si el cliente es activo en el banco (0 = No, 1 = Sí).	Binaria
EstimatedSalary	Estimación del salario anual del cliente.	Numérica

1. Estructura de los Datos

1. ¿Cuántas variables tiene la base de datos?
2. ¿Cuántas son cuantitativas?
3. ¿Cuántas son categóricas o binarias?
4. ¿Qué implicaciones tiene esta combinación de variables para el análisis estadístico?

2. Análisis Descriptivo Univariado

5. Muestre las distribuciones de las variables que considere relevantes e interprete estos datos.

3. Análisis Bivariado con la Variable Respuesta

6. Compare la distribución de Age entre clientes que abandonan y los que permanecen.
   - ¿Se observan diferencias relevantes?
7. Analice la relación entre IsActiveMember y Exited.
   - ¿Los clientes activos presentan menor abandono?
8. Evalúe la relación entre NumOfProducts y Exited.
   - ¿Mayor número de productos se asocia con menor churn?
9. Identifique qué variable parece tener mayor relación con el abandono, justificando con base en distribuciones comparativas.

4. Interpretación del Modelo: Odds Ratios

10. Identifique los factores de riesgo y los factores protectores del modelo. Recuerde: los odds ratios mayores que 1 son factores de riesgo; los odds ratios menores que 1 son factores protectores.

5. Aplicación Práctica: Evaluación de Perfiles de Clientes

Utilizando la calculadora de churn, estime la probabilidad de abandono para los siguientes casos:

Caso 1: Cliente poco vinculado

- CreditScore: 650
- Geography: France
- Gender: Female
- Age: 40
- Tenure: 5
- Balance: 100000
- NumOfProducts: 1
- HasCrCard: 0
- IsActiveMember: 0
- EstimatedSalary: 100000

Probabilidad estimada: _____

Caso 2: Cliente joven y activo

- CreditScore: 720
- Geography: Spain
- Gender: Male
- Age: 30
- Tenure: 6
- Balance: 50000
- NumOfProducts: 2
- HasCrCard: 1
- IsActiveMember: 1
- EstimatedSalary: 80000

Probabilidad estimada: _____

Caso 3: Cliente mayor con alto saldo e inactivo

- CreditScore: 580
- Geography: Germany
- Gender: Female
- Age: 55
- Tenure: 3
- Balance: 150000
- NumOfProducts: 1
- HasCrCard: 1
- IsActiveMember: 0
- EstimatedSalary: 90000

Probabilidad estimada: _____

Caso 4: Cliente altamente vinculado

- CreditScore: 700

- Geography: France
- Gender: Male
- Age: 45
- Tenure: 9
- Balance: 120000
- NumOfProducts: 3
- HasCrCard: 1
- IsActiveMember: 1
- EstimatedSalary: 110000

Probabilidad estimada: _____

6. Análisis Comparativo Final

11. ¿Cuál de los cuatro clientes presenta mayor riesgo de abandono?
12. ¿Qué variables parecen explicar las diferencias observadas?
13. Desde el punto de vista estratégico, ¿a cuál cliente priorizaría para una campaña de retención?

7. Matriz de Confusión y Métricas de Clasificación

14. A partir de la matriz de confusión mostrada en la aplicación, identifique los valores de:
    - TP (Verdaderos Positivos)
    - TN (Verdaderos Negativos)
    - FP (Falsos Positivos)
    - FN (Falsos Negativos)

Explique qué representa cada uno en el contexto de predicción de churn.

15. Con base en los valores anteriores, calcule manualmente los siguientes indicadores utilizando sus fórmulas:

Exactitud (Accuracy): Accuracy = (TP + TN) / (TP + TN + FP + FN)

Sensibilidad (Recall, clase Churn): Sensibilidad = TP / (TP + FN)

Especificidad: Especificidad = TN / (TN + FP)

Interprete cada resultado en el contexto del modelo de predicción de abandono y compare con los valores reportados por la aplicación.

Objetivo del Taller

Este ejercicio busca que el estudiante:

- Muestre e interprete distribuciones de variables relevantes.

- Analice relaciones bivariadas con la variable respuesta.
- Identifique factores de riesgo (OR > 1) y factores protectores (OR < 1) a partir de los Odds Ratios.
- Relacione resultados estadísticos con decisiones de negocio.