Taller: segmentacion RFM en datos de ventas minoristas

Algoritmos de Tipo No Supervisado

Curso ML Finanzas

2026-04-09

Trabajaras con una tabla de transacciones retail donde cada fila es una compra. El objetivo es comprender el comportamiento de los clientes y aplicar el modelo **RFM** (Recencia, Frecuencia, Monto) para segmentar y apoyar decisiones comerciales.

Sobre la base de datos

La base de datos transaccional es datos_de_ventas.csv. Significado de cada variable:

- **`ID_Transaccion`:** identificador unico de cada transaccion.
- **`Fecha`:** fecha de la transaccion (tendencias en el tiempo).
- **`ID_Cliente`:** identificador unico del cliente.
- **`Genero`:** genero del cliente (por ejemplo Masculino / Femenino).
- **`Edad`:** edad del cliente (segmentacion y perfiles).
- **`Categoria_Producto`:** categoria del articulo (por ejemplo Electronica, Ropa, Belleza).
- **`Cantidad`:** unidades compradas en esa linea.
- **`Precio_Unitario`:** precio por unidad.
- **`Importe_Total`:** importe total de la linea de transaccion.

Cada campo ayuda a describir la operacion y el comportamiento de compra; combinados permiten ver patrones y relaciones entre clientes y productos.

Como se usan las variables en el modelo RFM

Idea RFM	Que usar en esta base
Identificar al cliente	`ID_Cliente`
Momento de la compra	`Fecha`
Frecuencia de compra	Numero de transacciones (filas) por cliente en el periodo o subconjunto analizado
Monto	Suma de `Importe_Total` por cliente
Comparar lineas de negocio	Filtrar por `Categoria_Producto` o usar todas las categorias (`TODOS`)
Perfil demografico	`Genero`, `Edad` (y derivados, por ejemplo generacion)

Orden sugerido de trabajo: configuracion e importaciones → carga y exploracion inicial → preparacion de fechas → analisis descriptivo → construccion de la funcion RFM → ejecucion del modelo → tablas de apoyo → visualizaciones → (opcional) RFM por categoria.

---

1. Configuracion

- Importa las librerias necesarias para manejo de datos, fechas, visualizacion y tablas.

- Define una ruta de trabajo clara para cargar el archivo de datos de forma reproducible.

---

2. Carga y exploracion inicial

- Carga la base y reporta cuantas **filas** y **columnas** tiene.
- Identifica el **tipo de dato** de cada columna.
- Muestra las primeras filas de la tabla.
- Presenta una vision general de la estructura de la base.
- Calcula el conteo de **valores faltantes** por variable.

---

3. Preparacion para RFM

- Convierte `Fecha` a tipo fecha/datetime.
- Verifica que existan las columnas necesarias para el calculo de RFM.
- Trata nulos en `Fecha`, `ID_Cliente` o `Importe_Total` si existen e indica cuantas filas afectas.
- Reporta el **rango** de fechas cubierto por la base.
- Identifica las categorias presentes en `Categoria_Producto`.

---

4. Analisis descriptivo (antes de segmentar)

4.1 Univariado: numericas y categoricas

- Resume **tendencia central y dispersion** de `Edad`, `Cantidad`, `Precio_Unitario` e `Importe_Total`.
- Calcula frecuencias y porcentajes de `Genero`.
- Calcula frecuencias de `Categoria_Producto`.
- Reporta cuantos **clientes unicos** hay y cuantas **transacciones** (filas) existen en total.

4.2 Graficos univariados

- Construye **histogramas** de las variables numericas relevantes.
- Elabora un **boxplot** de `Importe_Total` por transaccion.

4.3 Bivariado: correlaciones

- Analiza la relacion entre `Cantidad`, `Precio_Unitario` e `Importe_Total`.
- Presenta una matriz de **correlacion** de las variables numericas.
- Complementa con un **mapa de calor** para facilitar la interpretacion.

4.4 Bivariado: tablas cruzadas

- Construye una tabla cruzada entre `Genero` y `Categoria_Producto`.
- Reporta los **conteos** absolutos.
- Calcula las **proporciones por fila** para comparar la composicion dentro de cada genero.

4.5 Monto segun categoria y genero

- Para cada `Categoria_Producto`, calcula el numero de transacciones, la suma de importes y el **importe promedio** por linea.
- Construye graficos de barras para comparar la suma y el promedio de `Importe_Total` por categoria.
- Elabora **boxplots** de `Importe_Total` por categoria y genero.
- Realiza un grafico de dispersion entre `Cantidad` e `Importe_Total`, distinguiendo por categoria.

4.6 Edad y categorias

- Analiza la distribucion de `Edad` segun `Genero`.
- Analiza la distribucion de `Edad` segun `Categoria_Producto`.
- Compara medianas y dispersion.

4.7 Rankings de clientes

- Identifica los clientes con mas **transacciones**.
- Identifica los clientes con mayor **importe total acumulado**.
- Identifica los clientes con mayor **precio unitario** en alguna linea.
- Si lo consideras util, compara tambien el **precio unitario promedio** por cliente.

4.8 Distribucion del importe y cruces

- Histograma de `Importe_Total` con ejes claros (puedes usar formato tipo moneda en el eje).
- Realiza un boxplot horizontal del importe.
- Realiza un boxplot por `Categoria_Producto`.
- Realiza boxplots por combinacion categoria + genero.
- Presenta una rejilla de histogramas de las variables numericas utiles.

4.9 Volumen y tiempo

- Construye un grafico de barras con el numero de transacciones por `Categoria_Producto`.
- Deriva de `Fecha` la **hora del dia** y el **dia de la semana**.
- Elabora un mapa de calor de actividad por hora y dia.
- Describe los patrones principales observados.

---

5. Modelo RFM: definicion

- Explica **Recencia**, **Frecuencia** y **Monto** para un cliente en este dataset.
- Explica como transformar cada dimension a puntajes **R, F y M** entre 1 y 5.
- Define un **indice ponderado** `RFM_nivel = peso_R*R + peso_F*F + peso_M*M`.
- Describe los **segmentos generales** que vas a usar.
- Describe los **subsegmentos** que vas a usar.
- Si lo deseas, incorpora una variable derivada de `Edad`, como **Generacion**, para enriquecer el perfil del cliente.

---

6. Ejecucion del modelo

- Ejecuta el modelo con pesos **0.1, 0.3, 0.6** para **todas** las categorias (`TODOS`).
- Muestra una vista preliminar de la tabla RFM resultante.
- Identifica la categoria con mayor numero de transacciones.
- Repite la ejecucion del modelo para esa categoria y compara la distribucion de segmentos frente al caso `TODOS`.

---

7. Tablas de apoyo

- Calcula el conteo de clientes por **segmento general**.
- Calcula el conteo de clientes por **subsegmento**.
- Resume por segmento general el numero de clientes y el **monto total**.

- Compara la distribucion de **genero** a nivel transaccion frente a la distribucion de genero a nivel cliente en la salida RFM.
- Reporta el **monto total** de la cartera segmentada.
- Reporta el numero total de clientes segmentados.
- Calcula las **transacciones promedio por cliente** en la base original.

7.1 Genero: distribucion en transacciones vs en clientes RFM

- Compara el conteo de `Genero` en la base original con el conteo de `cliente_genero` en la tabla RFM.
- Interpreta si hay diferencias entre la estructura transaccional y la estructura agregada por cliente.

7.2 Indicadores agregados de la cartera RFM

- Calcula la suma total de `Monto` en la tabla RFM.
- Reporta el numero de clientes presentes en la tabla RFM.
- Calcula el promedio de transacciones por cliente en la base original.

---

8. Visualizaciones del resultado RFM

- Construye un grafico de barras ordenado de clientes por **segmento general**.
- Construye un grafico de barras por segmento general desagregado por **genero**.
- Construye un grafico de barras por segmento general desagregado por **generacion**, si generas esta variable.
- Construye un grafico horizontal que cruce **segmento general** y **subsegmento**.
- Presenta un mapa de calor de **recencia media** por cruce entre segmento general y subsegmento.

8.1 Mapa de calor: conteos General_Segment x Segment

- Construye un mapa de calor con el **numero de clientes** en cada combinacion de segmento general y subsegmento.

8.2 Estrategia: Diamante y subsegmento Proximos a Perder

- Filtra los clientes clasificados como **Diamante** y simultaneamente en **Proximos a Perder**.
- Muestra una tabla de esos clientes.
- Exporta el resultado a CSV si deseas usarlo como insumo de estrategia comercial.

8.3 Muestra del dataframe RFM

- Presenta las primeras filas de la tabla RFM final.

8.4 Barras horizontales: participacion por subsegmento

- Construye barras horizontales de frecuencia de `Segment`.
- Etiqueta cada barra con su conteo y porcentaje sobre el total.

8.5 Distribucion de scores R y F; M condicionado a cada par (R,F)

- Grafica la distribucion de puntajes **R**.
- Grafica la distribucion de puntajes **F**.
- Construye una rejilla de distribuciones de **M** para cada combinacion de valores `(R, F)`.

---

9. (Opcional) RFM por categoria de producto

- Calcula RFM por separado para **Belleza**, **Ropa** y **Electronica** usando los mismos pesos.
- Compara el numero de clientes por categoria.
- Compara la distribucion de segmentos generales entre categorias.
- Compara la distribucion de subsegmentos entre categorias.

---

10. Analisis alternativo con nuevos pesos

En este punto se repite la logica de los apartados **6** y **7**, pero modificando la ponderacion del modelo a:

- **Recencia:** `0.05`
- **Frecuencia:** `0.15`
- **Monto:** `0.80`

El objetivo es evaluar como cambia la segmentacion cuando el **Monto** adquiere un peso mucho mayor dentro del indice RFM.

10.1 Ejecucion del modelo con los nuevos pesos

- Ejecuta nuevamente el modelo para **todas** las categorias (`TODOS`) usando los pesos `0.05`, `0.15` y `0.80`.
- Muestra una vista preliminar de la nueva tabla RFM.
- Repite la ejecucion del modelo para la categoria con mayor numero de transacciones.
- Si lo deseas, extiende tambien el analisis a **Belleza**, **Ropa** y **Electronica** por separado.

10.2 Tablas de apoyo con los nuevos pesos

- Calcula el conteo de clientes por **segmento general** con los nuevos pesos.
- Calcula el conteo de clientes por **subsegmento** con los nuevos pesos.
- Resume por segmento general el numero de clientes y el **monto total** bajo esta nueva ponderacion.
- Compara la distribucion de **genero** en la base transaccional frente a la distribucion de genero en la nueva salida RFM.
- Reporta el monto total segmentado y el numero total de clientes bajo esta nueva configuracion.

10.3 Comparacion del analisis: pesos originales vs nuevos pesos

- Compara los resultados con los obtenidos en el punto 6 usando pesos `0.1`, `0.3` y `0.6`.
- Analiza como cambia la distribucion de clientes entre **Diamante**, **Oro**, **Plata** y **Bronce**.
- Identifica que subsegmentos aumentan o disminuyen con mayor fuerza cuando el peso del **Monto** sube a `0.80`.
- Describe si los clientes de mayor gasto pasan a ocupar posiciones mas altas en la clasificacion general.

10.4 Comparacion general y por producto

- Explica como cambia el analisis **general** al pasar de los pesos originales a los nuevos pesos.
- Explica como cambia el analisis **por categoria de producto** (`Belleza`, `Ropa`, `Electronica`).
- Compara si el efecto del nuevo peso del **Monto** es similar en todas las categorias o si algunas se ven mas afectadas que otras.
- Concluye que tipo de estrategia comercial favorece mas esta nueva ponderacion: una centrada en clientes frecuentes o una centrada en clientes de alto gasto.